

# 前 言

5G 商用之后无线通信面临发展模式、架构以及安全等多方面的挑战,难以满足移动数据流量爆炸式增长以及业务多样化的需求。鉴于此,世界通信强国纷纷着手 6G 的战略布局并展开前瞻性研究。6G 将具备全覆盖、全应用、全频谱、强安全等显著特征,将从信息广度、信息深度以及信息速度等维度全面发展使能技术,预期在频谱效率、能量效率、智能、安全及隐私保护等关键性指标方面有数量级式的提升。为实现 6G 极具挑战性的愿景目标,需要在基础理论与关键技术上取得突破,相关研究已在先进信号处理、新型信道编码与调制、太赫兹通信、人工智能与无线通信结合的智能通信等领域迅速展开,其中探索以人工智能提升无线传输效能的智能通信已成为国际研究前沿领域。

智能通信被认为是 5G 之后无线通信发展主流方向之一,其基本思想是将人工智能引入无线通信系统的各个层面,实现无线通信与人工智能技术有机融合,以实现大幅度提升无线通信系统效能的愿景。学术界和工业界正在上述领域开展研究工作,前期的研究成果集中于应用层和网络层,主要将人工智能特别是深度学习引入到无线资源管理和分配等领域。目前,该方向的研究正在向 MAC (媒体访问控制)层和物理层推进,特别是在物理层已经出现无线传输与人工智能结合的趋势,各项研究目前处于探索阶段。

本书结合国内外学术界在智能通信领域的最新研究进展,着眼于基于深度学习的物理层设计,对相关理论基础、通信模块设计以及算法实现等进行详尽地介绍与分析。全书共 10 章,内容包括智能通信当前研究进展、神经网络的基础及进阶技巧、典型神经网络、基于深度学习的 QAM(正交调制)解调器设计、人工智能辅助的 OFDM (正交频分复用)接收机、CSI (信道状态信息)反馈及信道重建、基于深度学习的序列检测器实现,以及基于深度学习的 Turbo 码译码等。

本书由东南大学移动通信国家重点实验室金石和台湾中山大学通讯技术实验室温朝凯组织编写并统稿,金石主要负责或参与撰写第 1、2、3、4、7、8、10 章,温朝凯主要负责或参与撰写第 3、5、6、7、8、9 章。此外,还要特别感谢东南大学移动通信国家重点实验室的张静、王霁超、刘庆、李梦圆、司鹏勃、刘祺、

高璇璇、姜培文、王天奇、陈彤、王锐、张梦娇、何云峰、李嘉珂、曹凡等研究生为本书所做的贡献。

限于作者认知水平和写作时间，对于本书中存在的错误或不足之处，恳请同行专家与读者给予批评指正，我们将不胜感谢！

作 者

于中国无线谷

2020 年 3 月

# 目 录

## 前言

第 1 章 绪论 .....	1
1.1 智能通信引言 .....	1
1.2 人工智能技术简介 .....	3
1.2.1 人工神经网络 .....	3
1.2.2 深度神经网络 .....	4
1.2.3 卷积神经网络 .....	5
1.2.4 循环神经网络 .....	5
1.2.5 生成对抗神经网络 .....	6
1.2.6 深度增强学习神经网络 .....	6
1.3 智能通信当前研究进展 .....	7
1.3.1 信道估计 .....	7
1.3.2 信号检测 .....	8
1.3.3 CSI 反馈与重建 .....	9
1.3.4 信道译码 .....	10
1.3.5 端到端无线通信系统 .....	11
1.4 总结与展望 .....	12
1.5 本章小结 .....	14
参考文献 .....	14
第 2 章 神经网络的基础 .....	16
2.1 监督学习 .....	18
2.2 分类问题 .....	19
2.3 线性回归 .....	22
2.4 逻辑回归 .....	25
2.5 逻辑回归的代价函数 .....	29
2.6 梯度下降法 .....	30
2.7 模型验证 .....	34
2.8 基于 TensorFlow 的二分类范例 .....	35
参考文献 .....	41
第 3 章 神经网络的进阶技巧 .....	42

---

3.1	多分类算法	42
3.2	激活函数	46
3.2.1	线性激活函数	47
3.2.2	Sigmoid 函数	47
3.2.3	tanh 函数	48
3.2.4	ReLu 函数	49
3.3	神经网络的训练准备	51
3.3.1	输入归一化	51
3.3.2	权重初始化	53
3.4	正则化	55
3.4.1	偏差和方差	55
3.4.2	Dropout 算法	56
3.4.3	补偿过拟合的其他方式	58
3.5	批量归一化	60
3.5.1	归一化网络的激活函数	60
3.5.2	BN 与神经网络的拟合	61
3.6	优化算法	62
3.6.1	Mini-Batch 梯度下降法	62
3.6.2	指数加权平均	63
3.6.3	动量梯度下降法	64
3.6.4	RMS prop	65
3.6.5	Adam 优化算法	65
3.6.6	学习率衰减	66
3.7	基于 TensorFlow 的两层神经网络实例	67
	参考文献	71
第 4 章	卷积神经网络	73
4.1	什么是卷积神经网络	73
4.1.1	计算机视觉	73
4.1.2	卷积神经网络	74
4.2	卷积神经网络基本原理	75
4.2.1	卷积神经网络的结构	75
4.2.2	卷积神经网络的层级组成及其原理	75
4.2.3	卷积神经网络的特点	81
4.3	卷积神经网络的经典网络	81
4.3.1	经典的卷积神经网络	81

---

4.3.2 AlexNet 概述 .....	81
4.3.3 VGGNet 概述 .....	82
4.3.4 ResNet 概述 .....	84
4.4 多层卷积神经网络实例 .....	86
4.5 本章小结 .....	91
参考文献 .....	91
<b>第 5 章 循环神经网络 .....</b>	<b>92</b>
5.1 什么是序列模型 .....	92
5.1.1 序列模型简介 .....	92
5.1.2 序列模型的符号定义 .....	93
5.2 循环神经网络模型 .....	94
5.2.1 RNN 的前向传播 .....	94
5.2.2 RNN 的反向传播 .....	96
5.2.3 不同类型的 RNN .....	98
5.2.4 长期依赖问题 .....	99
5.3 长短时记忆 .....	100
5.3.1 长短时记忆网络 .....	100
5.3.2 LSTM 的变形与演进 .....	103
5.3.3 LSTM 实例应用 .....	106
5.4 本章小结 .....	108
参考文献 .....	108
<b>第 6 章 正交调制解调器 .....</b>	<b>109</b>
6.1 基于深度学习的 QAM 解调器设计 .....	109
6.1.1 基本原理 .....	109
6.1.2 SNR vs BER 仿真结果 .....	112
6.2 基于深度学习的 QAM 解调器设计 .....	117
6.2.1 QAM 解调的评价标准 .....	117
6.2.2 基于深度学习的 QAM 解调 .....	117
6.3 本章小结 .....	127
<b>第 7 章 人工智能辅助的 OFDM 接收机 .....</b>	<b>128</b>
7.1 FC-DNN OFDM 接收机 .....	129
7.1.1 系统结构 .....	129
7.1.2 模型训练 .....	130
7.1.3 仿真代码 .....	131
7.2 ComNet OFDM 接收机 .....	140

7.2.1	整体架构	140
7.2.2	信道估计子网	142
7.2.3	信号检测子网	143
7.2.4	仿真代码	145
7.3	仿真性能分析	148
7.3.1	仿真参数	148
7.3.2	整体 ComNet OFDM 接收机的仿真性能	148
7.4	本章小结	151
	参考文献	151
第 8 章	CSI 反馈及信道重建——CsiNet	152
8.1	CSI 反馈背景知识	152
8.2	基本原理	153
8.2.1	系统模型	153
8.2.2	压缩感知	155
8.2.3	自动编码器	155
8.3	基于深度学习的 CSI 反馈	156
8.3.1	基于深度学习的反馈机制	156
8.3.2	信道状态信息反馈网络 (CsiNet) 结构	157
8.4	实验结果与分析	159
8.4.1	实验数据生成	159
8.4.2	实验程序	160
8.4.3	实验仿真结果	166
8.5	CsiNet-LSTM	169
8.6	本章小结	177
	参考文献	177
第 9 章	滑动窗序列检测方法	179
9.1	序列检测	179
9.1.1	序列检测的基本原理	179
9.1.2	最大似然序列检测准则 <sup>[2]</sup>	180
9.1.3	维特比算法	181
9.2	基于深度学习的序列检测器实现	185
9.2.1	问题描述	186
9.2.2	深度学习实现	187
9.2.3	仿真分析	191
9.2.4	结果分析	198

---

9.3 本章小结	199
参考文献	199
<b>第 10 章 基于深度学习的 Turbo 码译码</b>	<b>200</b>
10.1 Turbo 码起源	200
10.2 Turbo 码编码原理	201
10.2.1 PCCC 型编码结构	201
10.2.2 SCCC 型编码结构	202
10.2.3 HCCC 型编码结构	203
10.3 Turbo 码传统译码算法	203
10.3.1 Turbo 码译码结构	204
10.3.2 MAP 算法	206
10.3.3 Log-MAP 算法	209
10.3.4 Max-Log-MAP 算法	210
10.4 基于深度学习的信道译码	210
10.4.1 优化传统“黑箱”神经网络	210
10.4.2 参数化传统译码算法	211
10.5 基于深度学习的 Turbo 码译码	216
10.5.1 模型的构建	216
10.5.2 性能仿真	226
10.5.3 仿真程序	228
10.6 本章小结	250
参考文献	250





# 第 1 章 绪 论

## 1.1 智能通信引言

自 2010 年以来, 5G 技术备受学术界和工业界的关注, 其主要特点为高维度、高容量、密集网络、低时延。相比于已经商用化的 4G 系统, 5G 无线传输速率提升 10~100 倍, 峰值传输速率达到 10 Gbit/s, 端到端时延降至毫秒级, 连接设备密度增加 10~100 倍, 流量密度提高 1000 倍, 频谱效率提升 5~10 倍, 能够在 500 km/h 的速度下确保用户体验。与面向人与人通信的 2G/3G/4G 不同, 5G 在设计之初, 就考虑了人与人、人与物、物与物的互连。国际电信联盟发布的 5G 八大指标包括: 基站峰值速率、用户体验速率、频谱效率、流量空间容量、移动性能、网络能效、连接密度和时延。

迄今为止, 5G 主要从 3 个维度实现上述指标, 即: 空口增强、更宽的频谱以及网络密集化。这 3 个维度最具代表性的使能技术分别对应于大规模多输入多输出(multiple input multiple output, MIMO)、毫米波通信以及超密集组网。大规模 MIMO 因具备提升系统容量、频谱效率、用户体验速率、增强全维覆盖和节约能耗等诸多优点, 被认为是 5G 最具潜力的核心技术。然而, 大规模 MIMO 的发展和应用也面临诸多问题, 如对于不具有上下行互易性的频分双工(frequency division duplex, FDD)系统, 如何有效地实现于基站侧获取信道状态信息。毫米波指的是波长在毫米数量级的电磁波, 其频率大约在 30~300 GHz 之间。现有的无线通信系统所用频段大多集中在 300 MHz~3 GHz 之间, 对毫米波频段的利用率较低。毫米波技术通过增加频谱带宽有效提高网络传输速率, 但会受传播路径损耗、建筑物穿透损耗和雨衰等因素的影响, 在实际应用中面临着巨大挑战<sup>[1]</sup>。另外, 毫米波通信可与大规模 MIMO 有机融合, 通过大规模 MIMO 波束成形带来的阵列增益可以弥补毫米波穿透力差的劣势。超密集组网(ultra dense network, UDN)通过更加“密集化”的无线网络部署, 将站间距离缩短为几十米甚至十几米, 使得网站密度大大增加, 从而提高频谱复用率、单位面积的网络容量以及用户体验速率。综合来看, 大规模 MIMO 利用超高天线维度充分挖掘利用空间资源, 毫米波通信利用超大带宽提升网络吞吐量, 超密集组网利用超密基站提高频谱利用率, 由此产生了海量的无线大数据, 为未来无线通信系统利用人工智能手段提供了数据源。

另一方面,近年来人工智能特别是深度学习(deep learning, DL)在计算机视觉、自然语言处理、语音识别等领域获得了巨大成功<sup>[2]</sup>,无线通信领域的研究者们期望将其应用于系统的各个层面,进而产生智能通信系统,实现真正意义上的万物互联,满足人们对数据传输速率日新月异的需求。因此,智能通信被认为是5G之后无线通信发展主流方向之一,其基本思想是将人工智能引入无线通信系统的各个层面,实现无线通信与人工智能技术有机融合,大幅度提升无线通信系统效能的愿景。学术界和工业界正在上述领域开展研究工作,前期的研究成果集中于应用层和网络层,主要思想是将人工智能特别是深度学习的思想引入到无线资源管理和分配等领域。目前,该方向的研究正在向MAC(medium access control)层和物理层推进,特别是在物理层已经出现无线传输与深度学习等结合的趋势,然而各项研究目前还处于初步探索阶段。

尽管无线大数据为人工智能应用于物理层提供可能<sup>[3]</sup>,智能通信系统的发展仍处于探索阶段,机遇与挑战并存。追溯历史,无线通信系统从1G演进至5G并获得巨大成功,其根源在于基于香农信息论的无线传输理论体系架构的建立与完善。一个典型的无线通信系统由发射机、无线信道和接收机构成,如图1.1所示。发射机主要包括信源、信源编码、信道编码、调制和射频发送等模块;接收机包括射频接收、信道估计、信号检测、解调、信道解码、信源解码以及信宿等模块。不同于典型的无线通信系统,智能通信的无线传输研究旨在打破原有的通信模式,获得无线传输性能的大幅提升。目前这方面的研究面临诸多挑战,国内外研究者们才开始初步探索。

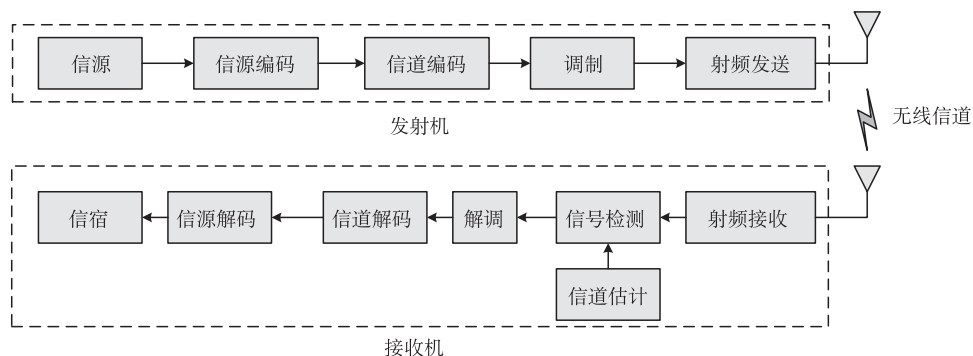


图 1.1 典型的无线通信系统

本书主要介绍人工智能技术,特别是深度学习应用于无线传输技术的最新研究进展,主要包括信道估计、信号检测、信道状态信息(channel state information, CSI)的反馈与重建、信道解码以及端到端的通信系统。

## 1.2 人工智能技术简介

### 1.2.1 人工神经网络

人工神经网络 (artificial neural network, ANN) 是 20 世纪 80 年代以来人工智能领域兴起的研究热点。它从信息处理角度对人脑神经网络进行抽象, 建立简单模型, 按不同的连接方式组成不同的网络。在工业界与学术界也常直接简称为神经网络或类神经网络。神经网络是一种由大量的节点 (或称神经元) 之间相互连接构成的运算模型, 神经元结构如图 1.2 所示。每两个节点间的连接都代表一个对于通过该连接信号的加权重, 称之为权重, 这相当于人工神经网络对该信息记忆的强度。每个节点自身则代表一种特定的输出函数, 称之为激活函数 (activation function)。整体的网络根据网络的连接方式、权重值和激活函数的不同构成不同的输出, 以逼近自然界某种算法或者函数, 或是达到某种逻辑策略。




图 1.2 神经元结构

1996 年 Langley 将机器学习定义为人工智能的一个分支, 旨在依赖经验知识提高系统性能。经过 20 世纪以来的长期研究, 研究者提出了逻辑回归、判定树、支持向量机和神经网络等各种算法。2006 年, Hinton 等在 *Science* 上发表论文, 其主要观点有: ①多隐藏层的人工神经网络具有优异的特征学习能力; ②可通过“逐层预训练”来有效克服深层神经网络在训练上的困难, 从此引出深度学习的研究<sup>[4]</sup>。此后, 深度学习在语音识别领域和图像识别领域取得巨大成就。深度学习作为一种新兴的神经网络算法, 具有多种结构, 包括深度神经网络 (deep neural network, DNN)、卷积神经网络 (convolutional neural network, CNN)、循环神经网络 (recurrent neural network, RNN)、生成对抗神经网络 (generative adversarial network, GAN) 和深度增强学习神经网络 (deep reinforcement learning neural network, DRLNN) 等。下面详细介绍这五种深度学习网络的基本结构。

### 1.2.2 深度神经网络

深度神经网络(DNN)也被称为多层感知机。DNN 基本结构如图 1.3 所示,由输入层、多个隐藏层和输出层构成。每个隐藏层包含多个神经元,每个神经元连接到相邻的层,同层神经元互不连接。单个神经元将各个输入与相应权重相乘,然后加偏置参数,最后通过非线性激活函数(激活函数类型见表 1.1)。DNN 可通过反向传播有效地优化,然后隐藏层和神经元数量的增加,将使得训练过程遇到如梯度消失、收敛缓慢以及收敛到局部最小值等问题,训练程序实现变得很困难。为了解决消失梯度问题,引入了新的激活函数来代替经典的 Sigmoid 函数。为了提高收敛速度和降低计算复杂度,经典梯度下降法(gradient descent, GD)被调整为随机梯度下降法(stochastic gradient descent, SGD),它随机选择一个样本来计算每次的损失和梯度。但随机特性在训练过程中会引起强烈的波动,因此,在经典的 GD 和 SGD 之间采用小批量随机梯度下降法(small-batch SGD)进行训练。然而,这些算法仍然会出现收敛于局部最优解。为了解决这一问题并进一步提高训练速度,数种自适应学习速率算法应运而生,如 Adagrad、RMSProp、Momentum、Adam 等<sup>[4]</sup>。训练完后还需注意是否有过拟合现象,如果训练后的网络在训练数据上表现良好,在测试过程中表现不佳,则出现过拟合现象。在这种情况下,为了在训练和测试资料上取得良好的结果,提出了正则化(regularization)和丢弃(dropout)等方案。




图 1.3 深度神经网络基本结构

表 1.1 激活函数类型

函数名称	函数表达式
Sigmoid	$\frac{1}{1+e^{-x}}$
tanh	$\tanh(x)$
ReLU	$\max(0, x)$

### 1.2.3 卷积神经网络

卷积神经网络(CNN)的基本结构由输入层、多个卷积层、多个池化层、全连接层以及输出层构成,如图1.4所示。卷积层和池化层采用交替设置,即一个卷积层连接一个池化层,池化层后再连接一个卷积层,依此类推。卷积层中卷积核的每个神经元与其输入进行局部连接,并通过对应的连接权值与局部输入进行加权求和,然后再加入偏置值,得到该神经元输出值。由于该过程等同于卷积过程,因此被称为卷积神经网络。




图 1.4 卷积神经网络基本结构

### 1.2.4 循环神经网络

循环神经网络(RNN)是一种对序列数据建模的神经网络,即一个序列当前的输出与前面的输出有关。具体的表现形式为:网络会对过去时刻的信息进行记忆并应用于当前输出的计算中,即隐藏层之间的节点不再是无连接的而是有连接的,并且隐藏层的输入不仅包括输入层,还包括上一时刻隐藏层的输出。图1.5是一个循环神经网络基本结构的示例。RNN旨在为神经网络提供记忆,因为输出不仅

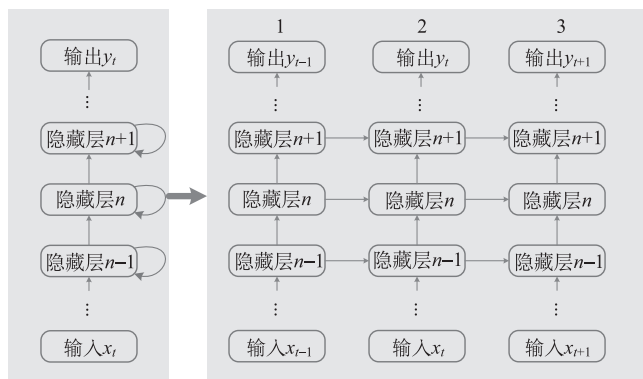


图 1.5 循环神经网络基本结构

依赖于当前输入，而且还依赖于过去时刻可用的信息或将来时刻可用的信息。图 1.5 所示的时延步长(time step)为 3。常用的 RNN 包括 Elman 网络、Jordan 网络、双向 RNN、长短时记忆(long short term memory, LSTM)和门控循环单元(gated recurrent units, GRU)。

### 1.2.5 生成对抗神经网络

生成对抗神经网络(GAN)是一种新型的分布学习生成方法，目的是学习一种能够在真实分布的数据集上生成伪样本的模型。GAN 基本结构如图 1.6 所示，包含一个生成器 G 和一个鉴别器 D。生成器和鉴别器均可由 DNN 实现。鉴别器用于区分生成器生成的伪样本和实际数据集的真样本，生成器的任务是生成样本数据使得鉴别器区分不出真样本和伪样本。在训练过程中，生成器将输入噪声  $z$  与样本的先验分布  $P(z)$  映像到一个样本；然后采集来自真实数据的样本和来自于生成器 G 的样本，以训练鉴别器 D，最大化区分这两类样本的能力。如果鉴别器 D 成功地对真样本和伪样本进行分类，那么它的成功可以反馈给生成器 G，从而促使生成器 G 学会生成与真样本更相似的样本。当生成器 G 所产生的样本让鉴别器 D 无法区分其与真样本的差异，训练便达到平衡。此时即可结束 GAN 的训练。

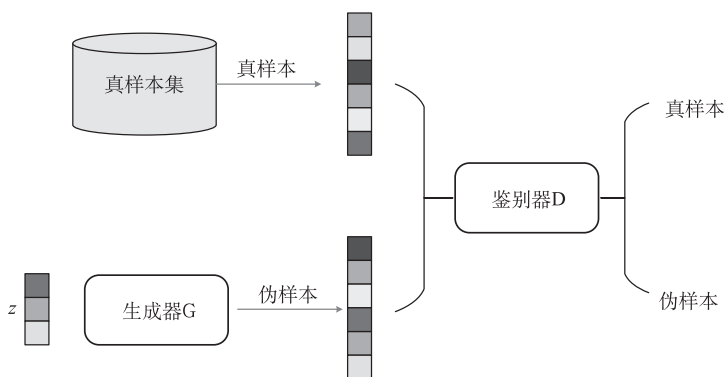


图 1.6 生成对抗神经网络基本结构

### 1.2.6 深度增强学习神经网络

强化学习目的是构造一个控制策略，使得 Agent 行为性能达到最大化。Agent 从复杂的环境中感知信息，对信息进行处理。Agent 通过学习改进自身的性能并选择行为，从而产生群体行为的选择，个体行为选择和群体行为选择使得 Agent 作出决策选择某一动作，进而影响环境。

增强学习(reinforcement learning, RL)是从动物学习、随机逼近和优化控制等

理论发展而来,是一种无导师在线学习技术,从环境状态到动作映像学习,使得 Agent 根据最大奖励值而采取最优的策略; Agent 感知环境中的状态信息,搜索策略(哪种策略可以产生最有效的学习)选择最优的动作,从而引起状态的改变并得到一个延迟回报值,更新评估函数,完成一次学习过程后,进入下一轮的学习训练,重复循环迭代,直到满足整个学习的条件,才终止学习。

深度增强学习(DRL)是一种端到端(end-to-end)的感知与控制系统,具有很强的通用性。其学习过程可以描述为:

(1)在每个时刻 Agent 与环境交互得到一个高维度的观察,并利用深度学习(DL)方法来感知观察,以得到具体的状态特征表示;

(2)基于预期回报来评价各动作的价值函数,并通过某种策略将当前状态映像为相应的动作;

(3)环境对此动作做出反应,并得到下一个观察。

通过不断循环以上过程,最终可以得到实现目标的最优策略。

DRL 原理框架如图 1.7 所示。

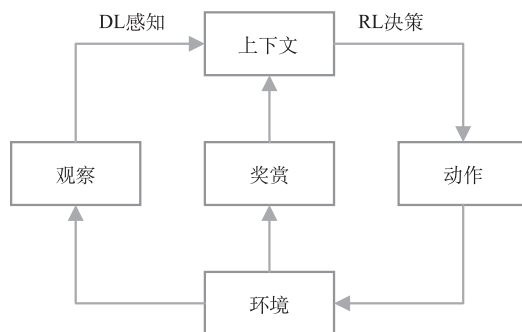


图 1.7 深度增强学习原理框架

## 1.3 智能通信当前研究进展

### 1.3.1 信道估计

在大规模 MIMO 波束毫米波场景下,信道估计极具挑战性,尤其是在天线数组密集、接收机配备的射频链路受限的场景。文献[5]提出 LDAMP(learned D-AMP)网络来解决这一信道估计问题。LDAMP 网络将信道矩阵视为二维图像作为输入,并将降噪的卷积神经网络融合到迭代信号重建算法中进行信道估计。LDAMP 网络是基于 D-AMP 算法<sup>[6]</sup>,由  $L$  层完全相同的结构串联而成。每层由降噪器、散度估量器和连接的系数组成。降噪器由具有 20 个卷积层的降噪卷积神经

网络(denoising convolutional neural networks, DnCNN)实现,在 LDAMP 网络中起到决定性作用。在未知噪声强度的情况下,DnCNN 降噪器能够解决高斯降噪问题,比其他降噪技术准确度更高、计算速度更快。DnCNN 通过学习残余噪声,然后通过相减操作获得信道估计的图像,而非直接从含有噪声的信道图像中学习信道图像,如此不仅降低了训练时间,也增强了信道估计的准确性。仿真结果表明 LDAMP 网络的性能优越于当前最具潜力的其他信道估计方法。

从最小均方差(minimum mean-square error, MMSE)算法的基本结构出发,文献[7]提出了一种基于深度学习的信道估计器,其中估计的信道向量由条件高斯随机变量组成,协方差矩阵具有随机性。根据协方差矩阵是否具有托普利茨(Toeplitz)特性和移不变(shift-invariance)的结构特性,MMSE 信道估计器的复杂度也有所不同。若不具备上述特性时,信道估计的复杂度将会变得很大。为了降低信道估计的复杂度,文献[7]在 MMSE 的架构基础上提出了利用 CNN 网络对误差进行补偿。仿真结果表明,提出的信道估计器在降低复杂度的同时,也保证了信道估计的准确性。文献[5]和文献[7]不仅考虑到实际问题中的模型特点,而且以现有算法为基础,使整个深度学习网络的学习参数较少,而且准确性高、复杂性低,更具竞争力。

### 1.3.2 信号检测

文献[8]利用 DNN 解决正交频分复用(orthogonal frequency division multiplexing, OFDM)系统中的信号检测问题。传统 OFDM 系统信道估计和信号检测是两个独立的功能模块,即首先进行信道估计获得信道状态信息(channel state information, CSI),然后利用估计的 CSI 恢复发送信号。如图 1.1 所示,信号原始恢复过程还涉及解调等模块。与传统无线通信不同,文献[8]将信道估计和信号检测视为一个整体,直接用 DNN 实现由接收信号到原始信号比特的映像;DNN 的输入为 256,隐藏层结构为 500-250-120,输出为 16,亦即 16bit;文中的 OFDM 系统采用 64 子载波,调制方式为正交相移编码(quadrature phase shift keying, QPSK),输入信号为 128 byte,因此需要 8 个相同结构的 DNN 进行训练。所提出的 DNN 在经大量数据训练以后,性能可与传统检测算法——最小均方差(MMSE)相比拟。此外,在无循环前缀或降低峰均功率比的 OFDM 非线性系统中,DNN 获得的性能要比传统的 MMSE 提升很多。然而,这种提升并非表明设计的合理性,因为误比特率也呈现一定的饱和性(饱和性是指随着信噪比的增大,信号检测的误比特率不再下降或下降不明显)。在实际系统中,非线性情况还没有得到很好解决。另外,需要提出的是一个子 DNN 需要训练 20000 次,一次训练涉及 50000 个样本,若要得到 8 个这样的网络,其训练时间和复杂度可想而知。

文献[9]研究的是 MIMO 系统的信号重建问题,为此提出了信号检测算法



DetNet。DetNet 是在最大似然法基础上加入梯度下降算法，从而生成一个深度学习网络。为了测试 DetNet 的鲁棒性，考虑了两种 CSI 已知的情景，即时不变信道和随机变量已知的时变信道。仿真结果表明，DetNet 性能优于传统的信号检测算法——近似消息传递 (approximate message passing, AMP) 算法，而且与半正定松弛 (semidefinite relaxation, SDR) 算法性能相当，具有极高的准确性和极少的时间开销 (SDR 算法速度是传统算法的 30 倍)。

文献[9,10]研究的问题相同，而且提出的解决方法均依赖已有的信号检测算法。文献[10]是以正交近似消息传递 (orthogonal approximate message passing, OAMP) 迭代算法为基础，结合深度学习网络提出了 OAMP-Net，目的是在原有算法基础之上，加入可调节的训练参数，进一步提升已有算法的信号检测性能。OAMP 算法在压缩感知领域被提出来解决稀疏线性求逆问题，后被用于 MIMO 的信号检测问题。与以往算法相比，OAMP 算法复杂度降低很多，但其信号检测性能有所下降。此外，其迭代的过程增加了算法的复杂度，为了弥补此缺陷，OAMP-Net 用  $T$  个串联层取代了算法的迭代过程。每个串联层不仅实现了 OAMP 算法的全过程，而且加入了一些可训练的参数，使得 OAMP 算法更具弹性，在参数改变时，不仅能适应更多信道场景，而且可以实现与其他算法模型的转换。仿真结果表明，OAMP-Net 的性能不仅优于 OAMP 算法，而且优于更加复杂的 LMMSE-TISTA 算法，其算法复杂度更低且能适应于时变信道。

不难看出，文献[8]提出的深度学习网络需要采集大量训练数据，前期训练工作量巨大，而文献[9,10]克服了这一困难，利用更简单的训练网络就可实现更好的信号检测性能。

### 1.3.3 CSI 反馈与重建

在频分复用网络中，MIMO 系统中基站需要获得下行链路的 CSI 反馈来执行预编码以及实现性能增益。然而大规模 MIMO 系统中的配置天线较多，造成过量反馈负载，因此传统的 CSI 反馈方法不再适用于此场景。文献[11]提出基于 CNN 的 CSI 感知与恢复机制 CsiNet。CsiNet 的感知部分也称为编码器，将原始 CSI 矩阵利用 CNN 转化为码本；CsiNet 的恢复部分也称为译码器，将接收到的码本利用全连接网络和 CNN 恢复成原始的 CSI 信号。编码器网络包括  $32 \times 32$  输入层、2 个  $3 \times 3$  卷积核、 $1 \times N$  重建层 (reshape) 和 1 个线性的  $1 \times M$  全连接层。译码器网络包括  $1 \times M$  输入层、 $1 \times N$  全连接层、 $32 \times 32$  重建层和 2 个 Refine 网络。Refine 网络用于特征提取，包括 4 层  $3 \times 3$  卷积层。文献[12]在压缩 CSI 反馈的空间复用 MIMO 系统中只利用 DNN 网络将原始 CSI 矩阵压缩为低维度的 CSI 信号，没有涉及 CSI 反馈信号的进一步恢复。

文献[13]在文献[11]基础上提出一种实时的基于 LSTM 的 CSI 反馈架构

CsiNet-LSTM, 该网络利用 CNN 和 RNN 网络分别提取 CSI 的空间特征和帧内相关性特征, 从而进一步提升反馈 CSI 的正确性。CsiNet-LSTM 的时延步长为  $T$ , 第一步时延步长的信道矩阵采用高压压缩率编码器, 其他  $(T-1)$  个时延步长采用低压压缩率编码器。 $(T-1)$  个低压压缩率编码器的输出码字分别与高压压缩率编码器的输出码字符串联在一起, 然后输入到相应的译码器中。最后的 CSI 重建由  $T$  个时延步长具有 3 层  $2 \times 32 \times 32$  单元的 LSTM 执行。需要指出的是, 此网络编码器和译码器部分与文献[11]的 CsiNet 结构完全相同。利用时变 MIMO 信道时间相关性和结构特点, CsiNet-LSTM 能实现压缩率、CSI 重建质量以及复杂度之间的折中。相比于 CsiNet, 该网络以时间效率换取了 CSI 的重建质量。参考文献[11,13]提出的 CSI 反馈与重建算法均依赖大量数据进行离线训练, 网络复杂度较高, 泛化性能需要深入研究。

### 1.3.4 信道译码

文献[14]提出了一种基于 DNN 的信道译码方法。该文献得出了深度学习应用于信道译码的两个结论: 一是如极化码等结构码比随机码更容易学习; 二是针对结构码, 深度学习网络能够译码没有训练过的码字。在接收端,  $k$  位信息比特被编码成长度为  $N$  的码字, 然后进行调制并通过发射机由噪声信道被送至接收端。接收端的信道译码器的任务是将接收的具有噪声干扰的码字恢复成相应的信息比特。信道译码器由输入层、3 层隐藏层、输出层构成。输入层为具有噪声干扰的码字, 输出层为信息比特。3 层隐藏层神经元结构为 128-64-32。信道译码深度学习用于信道译码无疑会受到维度爆炸的限制, 对于码长为 100, 码率为 0.5 的编码来说, 则存在  $2^{50}$  种不同的码字。因此, 该网络只适应于码字较短的信道编码技术。仿真结果表明, 对于结构码来说, 训练  $2^{18}$  次则接近最大后验概率 (maximum a posteriori probability, MAP) 译码器的性能。而对于随机码来说, 训练  $2^{18}$  次性能远远不及 MAP 译码器。另外, 文献[14]分别对不同的隐藏层结构 128-64-32、256-128-64、512-256-128 和 1024-512-128 进行比较, 对于此译码网络来说, 隐藏层结构越复杂, 训练的次数越多, 该译码器的性能越优越。

文献[14]将解码部分视作一个黑盒子, 直接实现了从接收码字到信息比特的转换, 该方式的性能虽然能与传统方法相比拟, 但是训练次数呈指数上升, 深度学习网络结构也足够复杂, 当码长发生改变时, 该网络需要被重新调整输入输出, 并重新训练, 工作量之大可想而知。另外, 该方法既不适应于随机码, 也不适合码长较长的码字, 具有很大的局限性。文献[15]与文献[14]不同, 是在传统极化码迭代译码算法基础上, 提出一种分离子块的深度学习极化码译码网络。该网络主要包含两个步骤: 一是将原编译码分割成  $M$  个子块, 然后分别对各个子块进行编码译码, 子块译码过程采用 DNN, 性能接近 MAP 译码器的性能, 子块的引入克